



به نام خدا



دانشگاه تهران
دانشکده مهندسی برق و کامپیوتر
رباتیک پیشرفته

پروژه نهایی
گروه شماره 6
اعضای گروه :
علی خیری 810603071
معین رضایی 810602091
محمدرضا توکلی 159403003

فهرست

4	 مقدمه
4	 توصیف مدل
5	 مراحل مدل IMM
5	 مرحله ی اول – ترکیب پیش بینی های مرحله ی قبل
6	 مرحله ی دوم – بروزرسانی احتمال مدل ها
6	 مرحله ی سوم – بروزرسانی تخمین حالت ها
7	 طراحی مدل و تنظیم پارامترها
9	 نتایج

در یک کالمن فیلتر ساده تنها یک مدل حرکت وجود دارد که اندازه گیری ها با توجه به آن اصلاح می شوند بنابراین اگر یک جسم چندین مدل حرکتی داشته باشد باید نویز فرآیند را افزایش داد تا اعتماد مدل به پیش بینی های خودش کمتر شود که در این صورت مدل به شدت jittery و پرنوسان می شود. اما در IMM(interacting multiple model) چندین مدل حرکتی در نظر گرفته شده که در هر مرحله هر کدام سعی در پیش بینی محل واقعی جسم می کنند و وزنی به هر مدل اختصاص داده می شود که معین میکند کدام مدل در هر مرحله بهتر رفتار جسم را توصیف کرده است. همچنین این مدل در برابر سیستم هایی که داینامیک و تغییرات زیادی دارند مقاوم تر می باشد.

نکته ی مهم دیگر این است که ترکیب نتایج مدل ها نیاز به یک تصمیم گیری منطقی ندارد که خطای سیستم را کاهش می دهد و سوئیچینگ وجود ندارد.

توصیف مدل


در حالیکه یک مدل کالمن فیلتر ساده در یک مرحله ی پیش بینی و یک مرحله ی اصلاح مطابق روابط زیر عمل میکند :

$$\begin{aligned}\bar{\mathbf{X}} &= \Phi \hat{\mathbf{X}} \\ \bar{\mathbf{P}} &= \Phi \hat{\mathbf{P}} \Phi^T + \mathbf{Q} \\ \mathbf{K} &= \bar{\mathbf{P}} \mathbf{H}^T (\mathbf{H} \bar{\mathbf{P}} \mathbf{H}^T + \mathbf{R})^{-1} \\ \hat{\mathbf{X}} &= \bar{\mathbf{X}} + \mathbf{K}(\mathbf{y}_k - \mathbf{H} \bar{\mathbf{X}}) \\ \hat{\mathbf{P}} &= (\mathbf{I} - \mathbf{K} \mathbf{H}) \bar{\mathbf{P}} ,\end{aligned}$$

تصویر شماره 1-1 روابط کالمن فیلتر

که تنها یک state transition matrix(Φ) و process noise matrix($\mathbf{Q}$) دارد.

در IMM برای هر کدام از مدل ها یک ماتریس به این شکل تعریف می شود همچنین یک مرحله ی ترکیب ورودی ها و تخمین وزن هر مدل هم وجود دارد.



نمودار شماره 1-1 دیگرام IMM

در ابتدا state estimation ها قبلی $\hat{\mathbf{x}}^1$ و احتمالات شرطی مدل ها $(\tilde{\mu}^{i/lj})$ ورودی state های قبلی به مدل ها را می سازند که خروجی $\hat{\mathbf{x}}^{01}$ که به همراه نوآوری اندازه گیری های جدید $(Z = \hat{m}_0 - \hat{m})$ برای بروزرسانی مدل ها استفاده می شوند که خروجی آن ها likelihood هر مدل به همراه state جدید می باشد. حال از likelihood به همراه احتمالات مدل قبلی $\hat{\mu}$ استفاده می شود تا احتمالات مدل های جدید محاسبه شوند. از احتمالات مدل ها برای جمع وزن دار حالت های پیش بینی شده مدل ها برای رسیدن به حالت فعلی خروجی IMM استفاده میشود.

مراحل مدل IMM

مرحله ی اول – ترکیب پیش بینی های مرحله ی قبل

$$\widehat{x^{0j}} = \sum_{i=1}^N x^i \widetilde{\mu^{ij}}$$

که x^i پیش بینی حالت مدل i ام در مرحله ی قبل و $\widetilde{\mu}$ احتمالات شرطی مدل هاست که برای محاسبه ی mixed state estimate استفاده شده.

$$\widehat{P^{0j}} = \sum_{i=1}^N \widetilde{\mu^{ij}} [\widehat{P^i} + (x^i - \widehat{x^{0j}})(x^i - \widehat{x^{0j}})^T],$$

که P^0 mixed state covariance است که برای هر مدل محاسبه می شود.

$$\widetilde{\mu^{ij}} = \frac{1}{\overline{\Psi^j}} p^{ij} \mu^i$$

$$\overline{\Psi^j} = \sum_{i=1}^N p^{ij} \mu^i$$

مرحله ی دوم – بروزرسانی احتمال مدل ها

$$\Lambda^i = \frac{1}{\sqrt{|2\pi S^j|}} \exp \left[-0.5 (Z^j)^T (S^j)^{-1} (Z^j) \right]$$

که z و s به ترتیب ماتریس نوآوری و کوواریانس نوآوری هستند.

$$Z^j = m_o(\text{vector observation}) - m^j(\text{projected prediction}), \text{innovation}$$

$$S^j = H^j \widehat{P^{0j}} (H^j)^T + R, \text{innovation covariance}$$

و احتمالات مدل ها طبق رابطه ی زیر با یک ضریب نرمال سازی c بروزرسانی می شوند.

$$\widehat{\mu^j} = \frac{1}{c} \Lambda^j \bar{c}^j$$

مرحله ی سوم – بروزرسانی تخمین حالت ها

و در نهایت تخمین نهایی مدل IMM از میانگین وزن دار تخمین هر یک از مدل ها به دست می آید.

$$\widehat{X} = \sum_{i=1}^N \widehat{x^i} \widehat{\mu^i}$$

$$\widehat{p} = \sum_{i=1}^N \widehat{\mu^i} [\widehat{p^i} + (\widehat{x^i} - \widehat{x})(\widehat{x^i} - \widehat{x})^T]$$

طراحی مدل و تنظیم پارامترها

از سه مدل حرکتی برای این مدل IMM استفاده شده :

1. مدل CV(constant velocity)

2. مدل CA(constant acceleration)

3. مدل CT(coordinated turn)

بردار حالت ما شامل $[x, y, dx/dt, dy/dt, dx/dt^2, dy/dt^2]$

می باشد. ماتریس state transition برای مدل CA به شکل زیر است:

$$F = \begin{bmatrix} 1 & 0 & \Delta t & 0 & \frac{1}{2}\Delta t^2 & 0 \\ 0 & 1 & 0 & \Delta t & 0 & \frac{1}{2}\Delta t^2 \\ 0 & 0 & 1 & 0 & \Delta t & 0 \\ 0 & 0 & 0 & 1 & 0 & \Delta t \\ 0 & 0 & 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 0 & 0 & 1 \end{bmatrix}$$

و process noise آن به صورت زیر تعریف شده :

$$Q_{ca} = q_{val} \begin{bmatrix} \frac{\Delta t^5}{20} & \frac{\Delta t^4}{8} & \frac{\Delta t^3}{6} & 0 & 0 & 0 \\ \frac{\Delta t^4}{8} & \frac{\Delta t^3}{3} & \frac{\Delta t^2}{2} & 0 & 0 & 0 \\ \frac{\Delta t^3}{6} & \frac{\Delta t^2}{2} & \Delta t & 0 & 0 & 0 \\ 0 & 0 & 0 & \frac{\Delta t^5}{20} & \frac{\Delta t^4}{8} & \frac{\Delta t^3}{6} \\ 0 & 0 & 0 & \frac{\Delta t^4}{8} & \frac{\Delta t^3}{3} & \frac{\Delta t^2}{2} \\ 0 & 0 & 0 & \frac{\Delta t^3}{6} & \frac{\Delta t^2}{2} & \Delta t \end{bmatrix}$$

مدل CV ماتریس انتقال حالت مشابه ایی دارد اما تفاوت آن در اجازه دادن به نویز فرآیند بسیار پایین تر روی شتاب آن می باشد.

Q_val برای CA مقدار 0.2 انتخاب شده و برای CV 0.01 روی سرعت ها و $10e-8$ برای شتاب ها

برای مدل CT چرخش با سرعت ثابت در نظر گرفته شده و همچنین سرعت چرخش هم مقداری ثابت در نظر گرفته شده چرا که برای در نظر گرفتن چرخش با سرعت های متغیر باید state vector دیگری طراحی میشد که مسئله را پیچیده می کند.

ماتریس state transition برای CT مطابق شکل زیر است:

$$F_{CT} = \begin{bmatrix} 1 & 0 & \frac{\sin(\omega\Delta t)}{\omega} & -\frac{1-\cos(\omega\Delta t)}{\omega^2} & 0 & 0 \\ 0 & 1 & \frac{1-\cos(\omega\Delta t)}{\omega} & \frac{\sin(\omega\Delta t)}{\omega^2} & 0 & 0 \\ 0 & 0 & \cos(\omega\Delta t) & -\sin(\omega\Delta t) & 0 & 0 \\ 0 & 0 & \sin(\omega\Delta t) & \cos(\omega\Delta t) & 0 & 0 \\ 0 & 0 & 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 0 & 0 & 1 \end{bmatrix}$$

نویز فرآیند نیمه بالایی ماتریس هم به شکل زیر می باشد

$$Q_{ct_4d} = q_{ct_pos_vel} \begin{bmatrix} \frac{\Delta t^3}{3} & 0 & 0 & 0 \\ 0 & \frac{\Delta t^3}{3} & 0 & 0 \\ 0 & 0 & \Delta t & 0 \\ 0 & 0 & 0 & \Delta t \end{bmatrix}$$

0.2 نویز شتاب و 0.005 نویز سرعت در نظر گرفته شده.

ماتریس انتقال بین مدل ها :

$$\begin{bmatrix} [0.97, 0.01, 0.01, 0.01], \\ [0.02, 0.96, 0.01, 0.01], \\ [0.02, 0.01, 0.96, 0.01], \\ [0.02, 0.01, 0.01, 0.96] \end{bmatrix}$$

که ترتیب مدل ها - سرعت ثابت ، شتاب ثابت و چرخش به چپ و چرخش به راست هستند. همچنین مدل با covariance matrix با اندازه 10 شروع شده است.

مسیر طراحی شده برای تست IMM مطابق تکه های زیر است :

1. 30 ثانیه حرکت با سرعت ثابت 15 در راستای x
2. 30 ثانیه حرکت با شتاب ثابت [2,1]
3. 30 ثانیه حرکت چرخشی در راستای ساعت گرد با سرعت 6deg/s
4. 30 ثانیه حرکت با سرعت ثابت با سرعت باقی مانده از حرکت های قبلی


همچنین پارامتر R که هم برای نویز مدل هم برای نویز اندازه گیری استفاده شده مقدار 10 قرار داده شده. و تنها از اطلاعات x,y شی در مدل اندازه گیری استفاده شده است.

تست با دیتای ربات :


برای این قسمت یک حرکت سه مرحله ایی سرعت ثابت شتاب ثابت و دور زدن در نظر گرفته شده و از همان مدل ترکیبی CA+CT برای IMM استفاده شده.

مدل حرکت داده شده و داده های odom و model state از gazebo در قالب یک فایل csv با نرخ 10 هرتز جمع آوری شده است.

نتایج



نمودار شماره 1-5 مسیر واقعی و مسیر دنبال شده با مدل IMM حالت $R=10$




نمودار شماره 2-5 احتمال هر مدل در طول زمان حرکت حالت $R=10$


تمایز بین حالت CV و CA به دلیل اینکه هر دو از یک مدل استفاده میکنند و در واقع سرعت ثابت همان شتاب ثابت با شتاب صفر می باشد کمتر دیده می شود. پس با کاهش نویز فرایند در حالت سرعت ثابت مخصوصا نویز مربوط به شتاب سعی شده این تمایز ایجاد شود برای اینکه در حالت سرعت ثابت مدل به سراغ CA نرود هم می شود یک تابع هزینه بر اساس پیچیدگی مدل

تعریف کرد تا در جاهایی که مدل ساده تر امکان توصیف حرکت را دارد از مدل شتاب دار استفاده نشود.

در مورد حرکت با سرعت ثابت هم گاهی با دنبالی از حرکت های چرخشی که جسم را چپ و راست میکنند مواجه می شویم مخصوصا اگر نویز اندازه گیری بالا باشد که با کاهش نویز فرآیند های چرخش ها می توان آن را کنترل کرد در کل بهترین عملکرد مدل در حالت چرخش به دست آمده است.




نمودار شماره 3-5 مسیر واقعی و مسیر دنبال شده با مدل IMM حالت $R=2$




نمودار شماره 4-5 احتمال هر مدل در طول زمان حرکت حالت $R=2$

با کاهش نویز عملکرد مدل طبق انتظار بهبود می یابد.

4-Model IMM with Specialized CV Model ($r = 20.0$)




نمودار شماره 5-5 مسیر واقعی و مسیر دنبال شده با مدل IMM حالت $R=20$




نمودار شماره 5-6 احتمال هر مدل در طول زمان حرکت حالت $R=20$

با افزایش نویز مدل قابلیت خود را از دست می دهد باید پارامتر های ماتریس کوواریانس و همچنین نویز های فرآیند تغییر کنند.

برای مثال با کاهش نویز فرآیند که اعتماد مدل به پیش بینی خودش را افزایش می دهد و حذف مدل CV که در تنش با مدل شتاب ثابت بود می توان به نتیجه بهتر زیر رسید.




نمودار شماره 5-7 مسیر واقعی و مسیر دنبال شده با مدل IMM با پارامتر های باز تنظیم شده
حالت $R=20$



نمودار شماره 5-8 احتمال هر مدل در طول زمان حرکت با پارامتر های باز تنظیم شده $R=20$

همچنین برای مقایسه یک کالمن فیلتر ساده در همین شرایط نویزی پیاده سازی شده :




نمودار شماره 5-9 مسیر واقعی و مسیر دنبال شده ی کالمن فیلتر تک مدله با $R=20$


نوع فیلتر	rms خطای مکانی (m)	rms خطای سرعت (m/s)
IMM	11.644	4.926
Kalman Filter	41.482	17.248

جدول شماره 5-1 مقایسه عملکرد کالمن فیلتر و IMM

نتایج تست ربات :



نمودار شماره 5-10 مسیر واقعی و مسیر دنبال شده با مدل IMM با پارامتر های بازتنظیم شده حالت $R=0.2$ برای داده های ضبط شده



نمودار شماره 5-11 احتمال هر مدل در طول زمان حرکت با پارامتر های باز تنظیم شده $R=0.2$ برای داده های ضبط شده.

به دلیل اختلاف خیلی کم مکان واقعی و مکان گزارش شده از odometry باید مقدار r به شدت کاهش می یافت همچنین نویز فرآیند مدل های چرخش نیاز به کم تر شدن داشت.

پدیده جالبی که مشاهده می شود این است که مدل حتی در حرکت شتاب ثابت هم به دلیل drift که در حرکت چرخ ها تشخیص داده چرخش به سمت راست را احتمال بیشتری داده اما در نهایت در چرخش به سمت چپ احتمال مدل اصلاح شده است.

Rms error ها هم وضعیت متعادلی را نشان می دهد.

Parameter	Value RMS error
Position	0.012 m
Velocity	0.045 m/s

وضعیت نمودار های نرم تر نسبت به شبیه سازی ما هم حاکی از این نکته هست که این داده ها از شبیه سازی و با نویز بسیار کمی استخراج شده اند پس تاثیر کمتری روی تغییرات احتمالات مدل ها دارند.